Курсов проект по дисциплината „Планиране на експеримента“

Тенчо Гюлтенов Бостанджиев - вариант V15

Фак. № 471223079 | Група 76

Това е Вашето индивидуално задание. Работите само върху файловете на варианта, разпределен по реда на списъка. Задачата е интегрирана и включва последователни етапи от всички 7 теми от конспекта: почистване на данни, разпределения, корелация, извадки, моделиране, прогнозиране и оптимизация.

1. Данни за Вашия вариант

Код на варианта: V15

Контекст: Производствена клетка - електроенергийно натоварване - подвариант C

Фактор z_t: Външна среда / товарен индекс

Файлове за работа: student_data/V15_raw.csv и student_data/V15_future.csv

Структура на входните файлове: Vxx_raw.csv съдържа t, x_norm, z_factor, y_raw; Vxx_future.csv съдържа t, x_norm, z_factor.

Размер и особености на данните: 120 наблюдения за t = 1..120, хоризонт за прогноза t = 121..126, 4 липсващи стойности и 3 аномални точки в наблюдавания сигнал.

Важно ограничение: използвайте само student_data файловете за Вашия вариант. Не използвайте instructor_data, truth файлове или предварително известни параметри на генератора.

> **Специален акцент за Вашия вариант:** *В етап 4 обсъдете как изборът на 8 интервала влияе върху дисперсията и медианата.*

2. Общата задача

Да се изгради напълно възпроизводим програмен проект, който започва от RAW данни, преминава през първична обработка, статистически анализ, моделиране и прогноза, и завършва с оптимизация на параметрите на избрания модел. Всички етапи трябва да бъдат реализирани с код; не се допуска решение, основано само на ръчна обработка в Excel или LibreOffice.

3. Етапи на изпълнение

Етап 0. Подготовка на проекта

Задание: Създайте проектова структура, импортирайте данните, проверете типовете на колоните, установете броя на редовете и запазете непроменено копие на RAW данните.

- Документирайте с каква команда се стартира проектът.
- Опишете използваните библиотеки и версията на езика/средата в README.txt.
- Подгответе папки поне source/ и results/ за кода и резултатите.

Етап 1. Първична обработка на данни

Задание: Постройте графика y_raw(t), открийте липсващите стойности и аномалните точки, сравнете поне един локален филтър от лекцията и още един допълнителен критерий по избор, интерполирайте липсващите стойности и постройте изгладен ред y_smooth(t).

- Сравнете поне два локални подхода, например F(1,1), F(2,1) или F(2,2), и аргументирайте избора на финален CLEAN pipeline.
- Създайте CLEAN.csv с най-малко следните колони: t, x_norm, z_factor, y_raw, y_clean, is_missing, is_outlier. Препоръчително е да добавите и y_smooth.
- Покажете графика с поне raw, y_clean и y_smooth върху една и съща времева ос.

Етап 2. Случайни величини и разпределения

Задание: Дефинирайте случаен компонент e_t = y_clean(t) - y_smooth(t). Оценете средна стойност, дисперсия, стандартно отклонение, медиана, квартилите и коефициент на вариация.

- Постройте хистограма и емпирична функция на разпределение за e_t.
- Сравнете e_t с нормално разпределение N(m_hat, s_hat^2). Не е нужно формален тест, но е нужен аргументиран коментар.
- Изведете кратък извод дали допускането за нормалност е разумно за Вашите данни.

Етап 3. Двумерни случайни величини, ковариация и корелация

Задание: Разгледайте двойките (z_t, y_clean(t)) за t = 1..120. Изчислете извадкова ковариация и коефициент на корелация на Пирсън.

- Постройте scatter plot на z_t спрямо y_clean.
- Коментирайте дали зависимостта изглежда линейна, силна, слаба или потенциално нелинейна.
- Не се ограничавайте само до числената стойност на r; тълкувайте резултата в контекста на варианта.

Етап 4. Данни от извадка - групирани и негрупирани оценки

Задание: Третирайте y_clean като извадка от генерална съвкупност. Изчислете статистиките първо върху негрупирани данни, а след това върху групирани данни с 8 равни интервала.

- Сравнете средна стойност, медиана, дисперсия, IQR и коефициент на вариация за двата подхода.
- Покажете таблица grouped срещу ungrouped.
- Коментирайте каква информация се губи при групиране на извадката.

Етап 5. Моделиране и оценка на грешката

Задание: Използвайте разделяне train/test с train = t = 1..90 и test = t = 91..120. Стандартизирайте регресорите по train частта:

u_t = (x_norm - mean_train(x_norm)) / std_train(x_norm),
v_t = (z_factor - mean_train(z_factor)) / std_train(z_factor)

Напаснете с МНМК следните два модела:

M1: y_t = beta0 + beta1*u_t + beta2*v_t + eps_t
M2: y_t = beta0 + beta1*u_t + beta2*v_t + beta3*v_t^2 + eps_t

- Изчислете MAE, RMSE и Bias върху train и test.
- Изберете по-добрия модел и защитете избора си с числа и кратък коментар.
- Покажете поне една графика на напасването и една таблица с оценените параметри.

Етап 6. Стохастично прогнозиране

Задание: За избрания модел дефинирайте остатъци r_t = y_clean(t) - y_hat(t) върху train частта. Оценете AR(1) модел r_t = phi*r_(t-1) + eta_t с метод на най-малките квадрати и използвайте V15_future.csv за прогноза на y_t за t = 121..126.

- Представете точкова прогноза и приблизителен 95% прогнозен интервал.
- Създайте forecast.csv с най-малко колони: t, x_norm, z_factor, y_forecast, lower95, upper95.
- Покажете графика на прогнозата заедно с последната част на наблюдавания ред.

Етап 7. Градиентни / квазиградиентни методи

Задание: Преоценете параметрите на избрания модел чрез projected gradient върху критерия J(theta) = mean((y - y_hat)^2) в train частта.

- Използвайте стартова точка theta^(0) = (mean(y_train), 0, 0, 0).
- Наложете ограничения: beta0 in [mean(y_train)-30, mean(y_train)+30], beta1, beta2, beta3 in [-20, 20].
- Използвайте стъпка rho_k = 1/(k+1). Стоп критерий: ||theta^(k+1)-theta^(k)||_2 < 1e-6 или k = 5000.
- Покажете графика на J(theta_k) спрямо k и сравнете получения резултат с МНМК. Ако е избран M1, игнорирайте beta3.

4. Задължителни изходни файлове и материали

- Архивът за предаване трябва да се казва 471223079_V15_PE.zip.
- Архивът трябва да съдържа поне: report.pdf, README.txt, source/, results/, CLEAN.csv и forecast.csv.
- report.pdf трябва да е 8-15 страници без приложения и да съдържа кратка теория, метод, резултати и изводи.
- README.txt трябва да съдържа команда за стартиране и кратко описание на файловете.
- results/ трябва да съдържа графики и таблици, използвани в отчета.

5. Минимален набор графики и таблици

- raw графика на y_raw(t)
- cleaned vs smooth графика
- хистограма и EDF на e_t
- scatter plot на z_t срещу y_clean
- таблица grouped срещу ungrouped статистики
- графика или таблица за model fit и грешки
- графика на прогнозата с 95% интервал
- графика на сходимостта на projected gradient

6. Програмни изисквания

- Решението трябва да е напълно програмно и възпроизводимо.
- Допускат се Python, MATLAB, R, Julia, C/C++ или друг език, но целият pipeline трябва да може да се изпълни с код.
- Не се допуска ръчна обработка като основен метод на решението.
- Всички формули, допускания и избрани критерии трябва да бъдат ясно описани в отчета.

7. Контролен checklist преди предаване

- Използвах само файловете за моя вариант.
- Имам CLEAN.csv и forecast.csv с коректни колони.
- Сравних M1 и M2 и избрах модел по обоснован начин.
- Направих прогноза за t = 121..126 и добавих интервал.
- Изпълних optimization етапа и показах сходимост.
- README.txt съдържа команда за стартиране.
- report.pdf съдържа всички графики, таблици и изводи.