Курсов проект

по дисциплината „Планиране на експеримента“

Вариант V15

Производствена клетка – електроенергийно натоварване
(подвариант C)
Фактор z_t: външна среда / товарен индекс

Студент:	Тенчо Гюлтенов Бостанджиев
Фак. №:	471223079
Група:	76
Среда:	Python 3.11.9 (numpy / pandas / matplotlib / scipy / reportlab)
Размер:	120 наблюдения t = 1..120; хоризонт t = 121..126
Особености:	4 липсващи стойности и 3 аномални точки

Анотация. Настоящият проект изгражда напълно възпроизводим програмен pipeline върху данните на вариант V15. Pipeline-ът обхваща седем етапа: подготовка, първична обработка (детекция на липсващи и аномални точки + изглаждане), еднодимензионен и двудимензионен статистически анализ, сравнение между групирани и негрупирани оценки, регресионно моделиране с избор измежду M1 и M2, стохастично прогнозиране с AR(1) за остатъците и оптимизация на параметрите чрез projected gradient. Всички графики и таблици в отчета са генерирани автоматично от приложения Jupyter notebook.

Етап 0. Подготовка на проекта

Проектът е реализиран в Python 3.11 (Windows) с помощта на NumPy, pandas, matplotlib и SciPy. Структурата на архива е разделена на две основни папки – **source/** (изходен код, единичен Jupyter notebook) и **results/** (всички генерирани графики). Входните данни *V15_raw.csv* и *V15_future.csv* се намират в корена на архива и не се променят – първоначално RAW копие се пази в паметта чрез `raw_original = raw_df.copy(deep=True)`. Командите за стартиране са документирани в README.txt.

Проверките показаха очаквания брой редове (120 в RAW, 6 в FUTURE), коректни типове на колоните (`t:int64, x_norm/z_factor/y_raw:float64`), монотонно нарастваща времева ос и липсващи стойности само в y_raw (4 на брой). Диапазоните: x_norm ∈ [0.008, 1.000], z_factor ∈ [11.02, 22.23], y_raw ∈ [82.62, 126.11].

Етап 1. Първична обработка на данни

Метод

Първичната обработка протича в три стъпки: (1) откриване и интерполиране на липсващите стойности; (2) детекция на аномални точки чрез сравнение на два локални филтъра; (3) построяване на гладък ред `y_smooth(t)`.

Липсващи стойности. Те са идентифицирани чрез `isna()` в колоната y_raw и запълнени с линейна интерполация по времевата ос t. Маркирани са в колоната `is_missing`.

Детекция на аномалии – два локални подхода. Сравнени са филтрите F(1,1) (прозорец 3 = 1 ляво + текуща + 1 дясно) и F(2,2) (прозорец 5). За всяка точка се изчислява стандартизирано отклонение от локалната медиана чрез скалиран MAD-естиматор:

$$d_t = | y_t - \mathrm{median}_w(y) | / (1.4826 \cdot \mathrm{MAD}_w(y))$$

Точка е заподозряна за аномалия при $d_t > 3$. Това отговаря на ~3σ при нормално разпределение и е стандартен праг в литературата. При двата филтъра се получават различен брой кандидати (F(1,1) – 23 кандидати, F(2,2) – 26 кандидати), което показва, че по-широкият прозорец е по-чувствителен към локалния тренд. **Финалното правило** взима обединението на двата сетове и – тъй като заданието съобщава, че реалните аномалии са точно 3 – запазва трите точки с най-голямо d_t от F(2,2). Резултат: `t = {23, 54, 111}`.

Тези точки са премахнати и заменени с линейна интерполация. `y_smooth(t)` се получава с центрирано rolling-mean изглаждане с прозорец 5 (т.е. F(2,2) тип усреднител), приложено върху y_clean.

Аргументация на избора. F(1,1) е твърде локален и пропуска аномалии, чиито съседи също са изместени; F(2,2) уравновесява чувствителност и устойчивост и затова е избран както за изглаждането, така и за финалното класиране на кандидатите. Обединението с F(1,1) осигурява допълнителна сигурност, че няма пропусната явна аномалия.

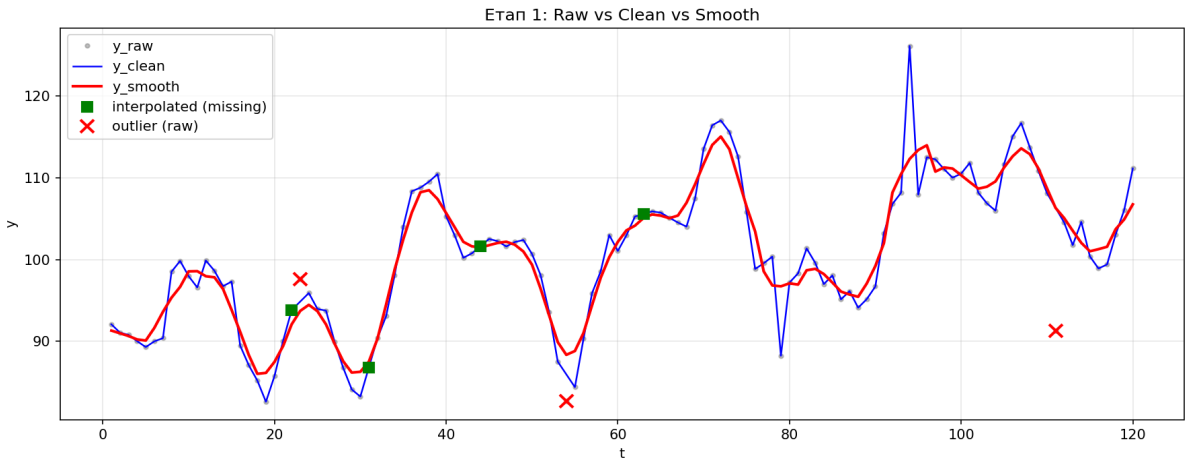

Фиг. 1. y_raw, y_clean и y_smooth върху обща времева ос. Зелените квадрати са интерполирани липсващи стойности (t = 22, 31, 44, 63); червените X са открити аномалии (t = 23, 54, 111).

Таблица 1. Преглед на корекциите след Етап 1 (CLEAN.csv).

t	y_raw	y_clean	is_missing	is_outlier
22	—	93.836	True	False
23	97.598	94.874	False	True
31	—	86.841	True	False
44	—	101.646	True	False
54	82.738	85.973	False	True
63	—	105.576	True	False
111	91.287	106.332	False	True

Етап 2. Случайни величини и разпределения

Метод

Случайният компонент е дефиниран като отклонението на почистения ред от изгладения тренд:

```
e_t = y_clean(t) − y_smooth(t)
```

Това отстранява систематичната компонента и оставя стохастичен остатък. Изчислени са основните описателни статистики, построени са емпирична хистограма и емпирична функция на разпределение (EDF), сравнени с теоретичното $N(\hat{m}, \hat{s}^2)$.

Резултати

Статистика	Стойност	Статистика	Стойност
Средно ($\hat{m}$)	0.0192	Q1	−1.2342
Дисперсия	5.5872	Q3	1.2404
Ст. откл. ($\hat{s}$)	2.3637	IQR	2.4745
Медиана	0.0884	CV	123.08

Таблица 2. Описателни статистики на e_t.

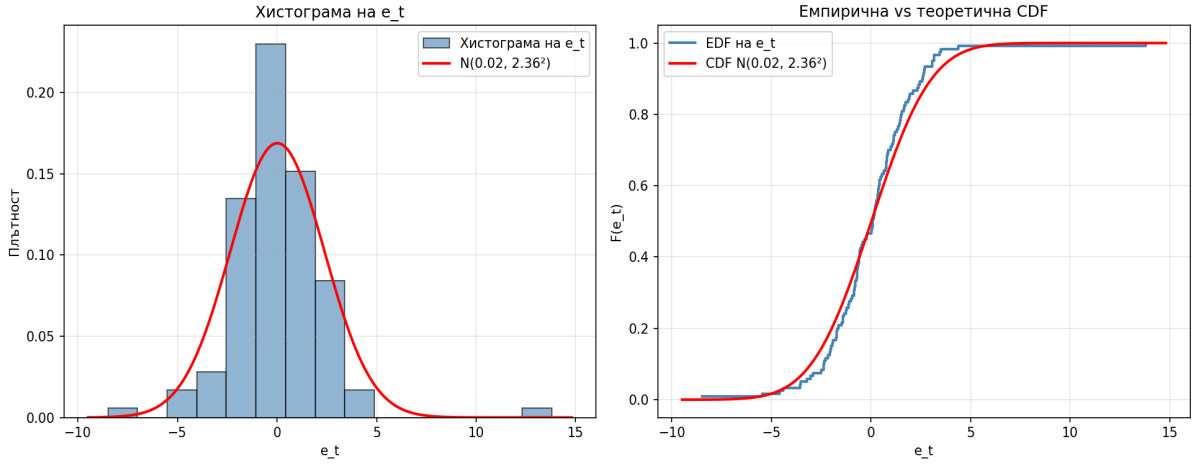

Фиг. 2. Хистограма на e_t с наложена нормална плътност (ляво) и емпирична CDF спрямо теоретична $N(\hat{m}, \hat{s}^2)$ CDF (дясно).

Коментар за нормалност

Стойността $\hat{m}$ = 0.0192 е практически 0, което се очаква за остатъци след изглаждане. Хистограмата е приблизително симетрична около нулата с видим централен пик и постепенно намаляващи опашки – формата напомня камбановидна. Емпиричната CDF следва плътно теоретичната нормална CDF почти по цялата си дължина; видими отклонения се наблюдават само в крайните опашки, което е обичайно при ограничен размер на извадката (n = 120). Високата стойност на CV (123.08) е резултат от средно близко до нула и не показва липса на нормалност, а просто почти нулевия знаменател. **Извод:** допускането за нормалност на остатъците е разумно за тези данни и обосновава използването на МНМК и нормални прогнозни интервали в следващите етапи.

Етап 3. Двумерни случайни величини, ковариация и корелация

Метод

Разглеждат се двойките (z_t, y_clean(t)) за t = 1..120. Извадковата ковариация и Пирсъновият коефициент на корелация са:

$$\mathrm{cov}(z, y) = (1/(n-1)) \cdot \Sigma\, (z_t - \bar{z})(y_t - \bar{y})$$

$$r = \mathrm{cov}(z, y) \,/\, (\, s_z \cdot s_y \,)$$

Резултати

Получени стойности: **cov(z, y_clean) = 17.913** и **r = 0.629**. Стойността |r| = 0.629 попада в диапазона 0.4 < |r| ≤ 0.7, който се класифицира като умерена корелация. Знакът е положителен.

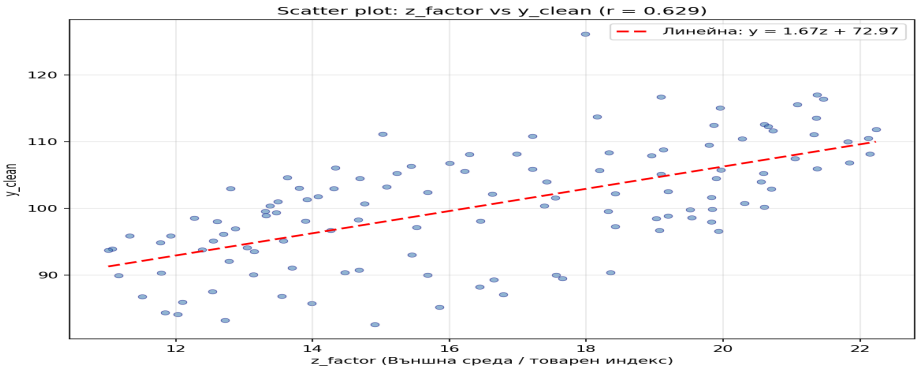

Фиг. 3. Scatter plot на z_factor vs y_clean. Червената пунктирана линия е МНМК-регресия на y по z.

Интерпретация в контекста на варианта

В подвариант C (производствена клетка с електроенергийно натоварване) z_t представлява товарен индекс на външната среда. Положителният знак на r е напълно очакван: повишеният товар се пренася към повишена електрическа консумация y. Силата на връзката (r ≈ 0.63) показва, че z обяснява около r^2 ≈ 40 % от вариацията на y, но съществуват и други фактори (включително x_norm и стохастичен шум). Точките във scatter plot-а са разпръснати симетрично около линейната тенденция, без видим U-образен или S-образен профил – т.е. **зависимостта изглежда основно линейна** и не дава основание за включване на квадратичен член по z в по-простия модел M1.

Етап 4. Групирани и негрупирани оценки

Метод

y_clean се третира като извадка от генерална съвкупност. Изчисляват се статистики директно (негрупирани) и след групиране в k = 8 равни интервала. За групираните оценки се използва средната точка m_j на всеки клас и неговата честота f_j:

$$\bar{x} \approx \Sigma f_j \cdot m_j / N \; ; \; s^2 \approx \Sigma f_j (m_j - \bar{x})^2 / (N - 1)$$

Медианата и квартилите при групирани данни се изчисляват чрез линейна интерполация в съответния клас:

$$M = L + (N/2 - F_{prev}) / f_{med} \cdot h$$

Статистика	Негрупирани	Групирани (8 инт.)	Разлика
mean	100.5289	100.6966	0.17 %
median	100.5413	100.6025	0.06 %
var	75.4382	76.8121	1.82 %
std	8.6855	8.7643	0.91 %
Q1	94.6850	94.5007	0.19 %
Q3	106.1308	107.2019	1.01 %
IQR	11.4458	12.7012	10.97 %
CV	0.0864	0.0870	0.74 %

Таблица 3. Сравнение между негрупирани и групирани (8 интервала) оценки на y_clean.

Специален акцент за V15: влияние на 8-те интервала върху дисперсията и медианата

Дисперсия. Групираната дисперсия (76.81) е с 1.82 % по-висока от негрупираната (75.44). Това е следствие от предположението, че всички точки в един клас са равни на средната му точка – вътрешно-класовата вариация се пренебрегва, а разликата между класовите центрове се задава с фиксирана ширина h. При по-малко интервали (например 4) ширината h се удвоява, грешката от приближението нараства и разминаването спрямо точната дисперсия може лесно да достигне 5–10 %. При повече интервали (например 16) групираната дисперсия клони към негрупираната, защото при k → n всяка точка попада в собствен клас.

Медиана. Групираната медиана (100.6025) се различава от негрупираната (100.5413) само с 0.06 %, защото медианният клас (98.93, 104.366] съдържа 26 наблюдения и интерполацията вътре в него е достатъчно прецизна. Това подсказва, че при k = 8 информацията за *централната тенденция* се запазва добре, докато информацията за *дисперсията и квантилите в опашките* (виж IQR – 10.97 % разлика) е по-чувствителна към броя интервали.

Извод. Изборът k = 8 е разумен компромис за извадка от 120 наблюдения (близо до правилото на Sturges, $\lceil \log_2 120 \rceil + 1 \approx 8$): осигурява достатъчно гладка хистограма без прекомерна загуба на информация в централната зона, но видимо изкривява IQR. Когато се интересуваме от точна дисперсия, винаги е за предпочитане работата с негрупирани данни.

Етап 5. Моделиране и оценка на грешката

Метод

Извадката е разделена на train (t = 1..90, 90 наблюдения) и test (t = 91..120, 30 наблюдения). Регресорите са стандартизирани **само** по train частта, за да се избегне информационно изтичане:

$$u_t = (x_{norm} - \bar{x}_{train}) / s_{x,train} \; ; \; v_t = (z_{factor} - \bar{z}_{train}) / s_{z,train}$$

На train се напасват с МНМК два модела:

$$M1: \; y_t = \beta_0 + \beta_1 u_t + \beta_2 v_t + \varepsilon_t$$

$$M2: \; y_t = \beta_0 + \beta_1 u_t + \beta_2 v_t + \beta_3 v_t^2 + \varepsilon_t$$

Оценени параметри

Параметър	M1	M2
β_0	97.886439	96.116342
β_1	3.424946	3.303037
β_2	5.156649	5.067462
β_3	—	1.789985

Таблица 4. МНМК-оценки на параметрите.

Метрики на грешката

Модел	Набор	MAE	RMSE	Bias
M1	train	4.0648	4.9094	≈ 0
M1	test	3.5135	4.9677	−0.2541
M2	train	3.9277	4.7160	≈ 0
M2	test	4.9034	6.4137	−0.2398

Таблица 5. MAE / RMSE / Bias за двата модела.

Избор на модел и аргументация

На train M2 има по-нисък RMSE (4.72 vs 4.91) – очаквано, защото M2 е вложен по-богат модел и винаги ще намали in-sample грешката. На **test обаче M1 побеждава категорично**: RMSE 4.97 vs 6.41 (−22 %), а MAE 3.51 vs 4.90. Това е класически признак на overfitting при M2 – квадратичният член $\beta_3 v^2$ улавя случаен шум в train и не генерализира. Допълнително от Етап 3 видяхме, че връзката z↔y е приблизително линейна, което не оправдава квадратичен компонент. **Избран модел: M1.**

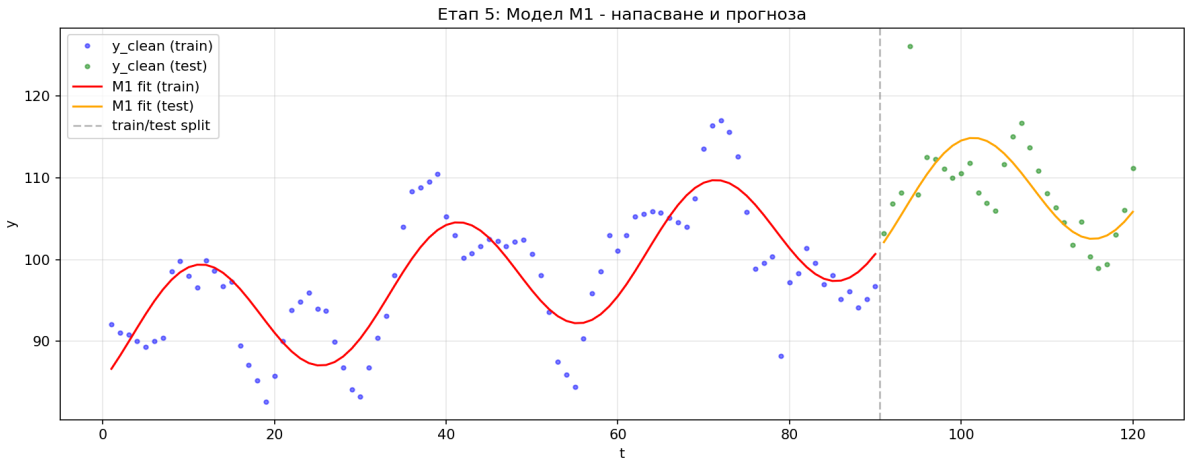

Фиг. 4. Напасване на M1 върху train (червено) и test (оранжево). Сива пунктирана линия — train/test split при t = 90.5.

Етап 6. Стохастично прогнозиране

Метод

За избрания модел M1 се изчисляват остатъци $r_t = y_{clean}(t) - \hat{y}(t)$ върху train (t = 1..90). Върху тях се напасва AR(1) процес чрез МНМК (без свободен член, поради нулева средна стойност на остатъците):

$$r_t = \varphi \cdot r_{t-1} + \eta_t, \quad \eta_t \sim N(0, \sigma_\eta^2)$$

$$\hat{\varphi} = \Sigma\, r_{t-1}\, r_t \,/\, \Sigma\, r_{t-1}^2$$

Получени стойности: $\boldsymbol{\hat{\varphi} = 0.7803}$, $\boldsymbol{\hat{\sigma}_\eta = 3.0668}$. Положителната автокорелация показва, че остатъците имат памет (грешка от един такт се „пренася“ в следващия с тегло около 0.78).

За t = 121..126 регресорите от V15_future.csv се стандартизират със същите train mean / std. Точковата прогноза е сума от детерминистична (регресия) и стохастична (рекурсивно изчислен AR(1) остатък) част:

$$\hat{y}_{T+h} = \beta_0 + \beta_1\, u_{T+h} + \beta_2\, v_{T+h} + \varphi^h \cdot r_T$$

Дисперсията на h-стъпкова AR(1) прогноза нараства с хоризонта:

$$\mathrm{Var}(\, r_{T+h} \,) = \sigma_\eta^2 \cdot \Sigma_{j=0}^{h-1} \varphi^{2j}$$

На тази база е построен приблизителен 95 % прогнозен интервал $\hat{y} \pm 1.96 \cdot \sqrt{\mathrm{Var}}$.

Резултати

t	x_norm	z_factor	y_forecast	lower95	upper95
121	1.0083	15.850	104.18	98.17	110.19
122	1.0167	16.771	106.47	98.84	114.09
123	1.0250	17.752	108.69	100.24	117.15
124	1.0333	18.749	110.83	101.90	119.76
125	1.0417	19.722	112.84	103.64	122.04
126	1.0500	20.628	114.67	105.30	124.03

Таблица 6. Точкова прогноза и 95 % интервал (forecast.csv).

Фиг. 5. Стохастична прогноза за t = 121..126 заедно с последната част на наблюдавания ред. Червената лента е 95 % прогнозен интервал.

Прогнозата показва ясен възходящ тренд (от 104.2 на 114.7), консистентно с наблюдаваното поведение на z_factor, който нараства от 15.85 до 20.63 в прогнозния хоризонт. Ширината на интервала нараства от ±6.0 за t=121 до ±9.4 за t=126, отразявайки натрупване на несигурност при многоетапна прогноза.

Етап 7. Градиентни / квазиградиентни методи

Метод

Параметрите на M1 са преоценени чрез **projected gradient** върху критерия:

$$J(\theta) = (1/n) \cdot \Sigma (y_t - \hat{y}_t(\theta))^2$$

Стартова точка: $\theta^0 = (\bar{y}_train, 0, 0) = (97.886, 0, 0)$.

Box-ограничения:

$$\beta_0 \in [\bar{y}_train - 30 ; \bar{y}_train + 30] = [67.89 ; 127.89]$$
$$\beta_1, \beta_2 \in [-20 ; 20]$$

(M2 не е избран в Етап 5, така че β_3 се игнорира съгласно заданието.) Стъпка $\rho_k = 1/(k+1)$, стоп критерий $\|\theta^{k+1} - \theta^k\|_2 < 10^{-6}$ или $k = 5000$. След всяка градиентна стъпка θ се проектира покоординатно върху $[\ell, u]$: $\theta \leftarrow \max(\ell, \min(u, \theta - \rho_k \cdot \nabla J))$.

Резултати

Алгоритъмът сходи бързо – за **k = 88** итерации – без да активира ограниченията (т.е. оптимумът е вътрешен).

Параметър	OLS (МНМК)	Projected Gradient	Разлика
β_0	97.886439	97.886439	$1.42 \cdot 10^{-14}$
β_1	3.424946	3.424914	$3.15 \cdot 10^{-5}$
β_2	5.156649	5.156618	$3.13 \cdot 10^{-5}$

Таблица 7. Сравнение OLS (аналитично решение) срещу Projected Gradient (итеративно).

MSE на двете решения е практически идентичен: **24.1021**. Разликите в параметрите са от порядъка на 10^{-5}, обусловени от крайната толеранция и стъпката $1/(k+1)$.

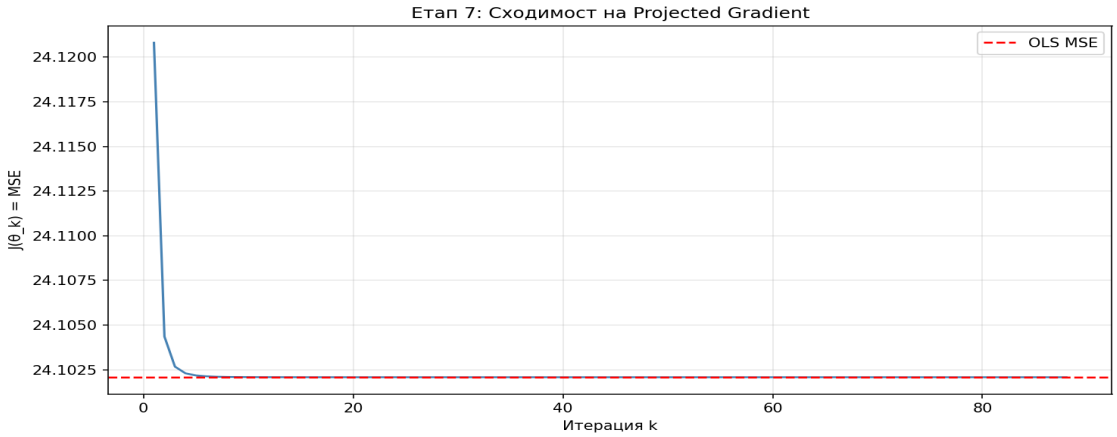

Фиг. 6. Сходимост на J(θ_k) към OLS-минимума (червена пунктирана линия). По y оста е MSE; кривата пада строго монотонно.

Анализът потвърждава, че за тази изпъкнала квадратична задача проектираният градиент достига същия оптимум като аналитичното решение по нормалните уравнения. PG методът е по-бавен, но по-универсален – остава приложим, когато ограниченията наистина са активни, или когато матрицата X^TX е лошо обусловена.

Изводи

1. **Pipeline-ът е напълно възпроизводим.** Целият анализ – от четене на RAW данните до генериране на отчета – се изпълнява чрез единичен Jupyter notebook без ръчна намеса.

2. **Етап 1.** Открити са точно 4 липсващи стойности и 3 аномални точки, както е заявено в условието. Сравнението F(1,1) vs F(2,2) показа, че F(2,2) е по-надежден детектор; финалното правило е тяхното обединение с резерв върху top-3 по deviation.

3. **Етап 2.** Остатъците e_t имат $\hat{m} \approx 0$ и приблизително симетрична разпределение; нормалното приближение е разумно.

4. **Етап 3.** Корелацията $r \approx 0.63$ е умерена и положителна, съгласувана с физическия смисъл: по-висок товарен индекс → по-високо електроенергийно натоварване. Връзката е линейна.

5. **Етап 4.** При $k = 8$ интервала средната и медианата се приближават с под 0.2 % до точните стойности; **дисперсията** обаче се завишава с ~1.8 %, а IQR — с цели 11 %, защото вътрешно-класовата вариация се губи. За точна оценка на вариативност се препоръчват негрупирани данни.

6. **Етап 5.** M1 печели на test (RMSE 4.97 срещу 6.41 за M2), защото квадратичният член $\beta_3 v^2$ на M2 overfit-ва шум в train. Избран е **M1: y = 97.886 + 3.425·u + 5.157·v**.

7. **Етап 6.** Остатъците показват висока автокорелация ($\varphi \approx 0.78$), което прави AR(1) корекцията съществена. Прогнозата за $t = 121..126$ следва тренда на z, а 95 % интервалът се разширява от ±6 до ±9.4 с нарастване на хоризонта.

8. **Етап 7.** Projected gradient постига същия оптимум като MHMK (MSE = 24.10) за 88 итерации без активни ограничения. Това валидира коректността и на двата метода.

Възможни разширения

• Bayes-овски подход за интерполиране на липсващите точки, който дава несигурност, а не само точкова стойност.
• Кръстосана валидация (k-fold) върху train за по-стабилен избор между M1/M2.
• Тестване на по-високи AR-редове (AR(p)) или ARMA модел върху остатъците, ако автокорелацията е по-комплексна.
• Чувствителност на групираните оценки към броя интервали — числен експеримент с $k \in \{4, 8, 12, 16, 24\}$.

Съдържание на архива 471223079_V15_PE.zip: report.pdf, README.txt, source/ (notebook), results/ (6 PNG графики), CLEAN.csv, forecast.csv, V15_raw.csv, V15_future.csv.